Домашнє завдання до теми «Apache Spark. Оптимізація та SparkUI»

Частина 1

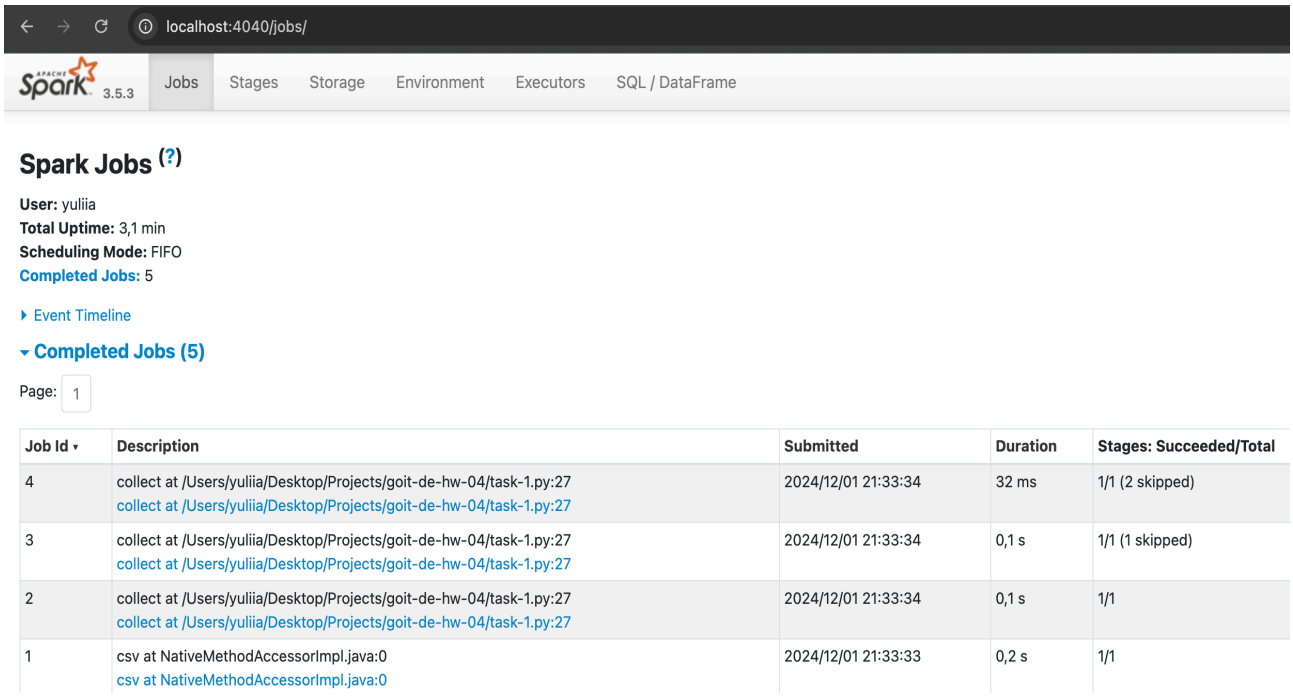

Результат:

Job 1: Spark ініціалізує завантаження даних із диска в DataFrame. Це включає визначення схеми даних та читання рядків із CSV-файлу.

Job 2: Spark переносить дані між розділами, щоб забезпечити рівномірний розподіл. Це корисно для паралельного обчислення.

Job 3: Spark виконує всі перетворення:

- Фільтрує рядки, де final_priority < 3.
- Вибирає стовпці unit_id і final_priority.
- Групує дані за unit_id і рахує кількість записів у кожній групі.

Job 4: Spark обчислює результат фільтрування, вибираючи тільки ті групи, де count > 2.

Job 5: Spark виконує всі попередні трансформації, якщо вони ще не були виконані, і збирає результати у формат, який може бути використаний у Python.

Частина 2

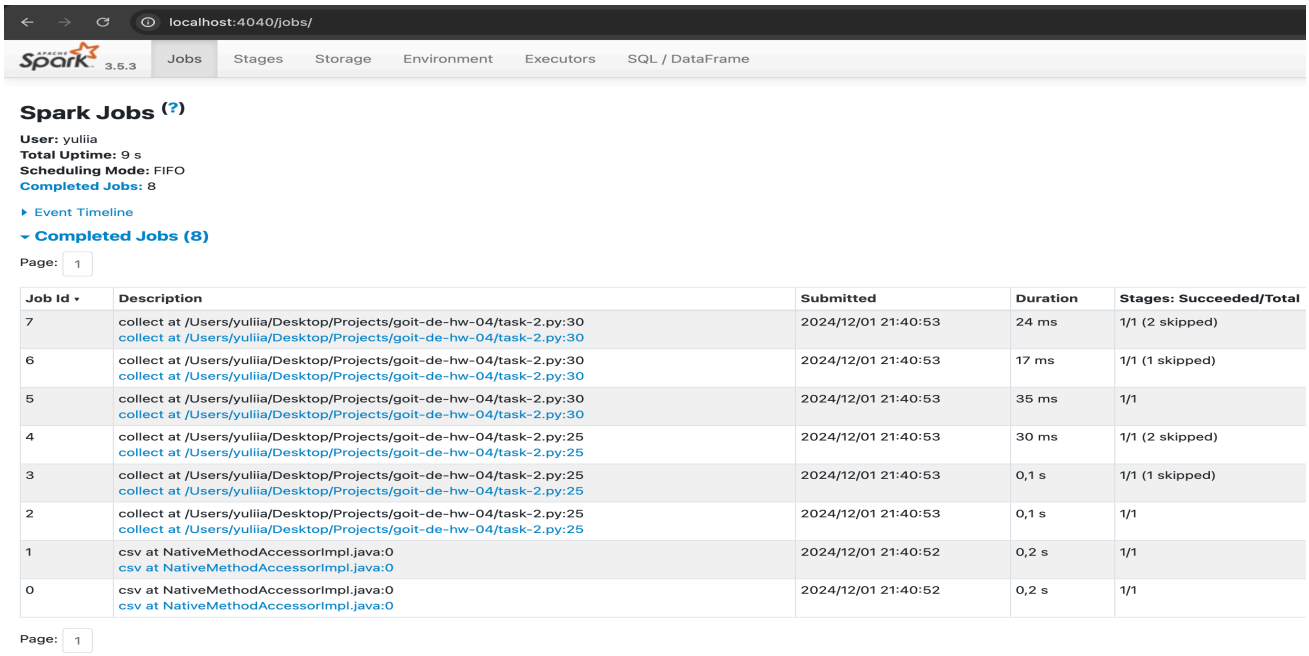

Чому при додаванні однієї проміжної дії nuek_processed.collect(), отримано аж на 3 Job більше?

Додавання проміжного collect() у код створює значний вплив на роботу Spark. Це пов’язано з тим, що collect()є дією (**action**), яка змушує Spark завершити виконання всіх попередніх трансформацій та завантажити результат у локальну пам’ять.

В результаті Spark двічі виконує обчислення:

1. Перший collect() викликає обчислення для всіх попередніх трансформацій (до groupBy і count включно).
2. Другий collect() запускає обчислення ще раз для додаткової фільтрації where("count > 2").

Тому кількість Jobs зросла:

- 1 Job для читання CSV-файлу.
- 1 Job для repartition.
- 1 Job для фільтрації where("final_priority < 3").
- 1 Job для select + groupBy + count.
- 1 Job для першого collect().
- Після першого collect() Spark завершує всі попередні обчислення.
- Далі, при другому collect():
    - 1 Job для фільтрації where("count > 2").
    - 2 Jobs для повторного обчислення групування (groupBy + count) і фільтрації.

Частина 3

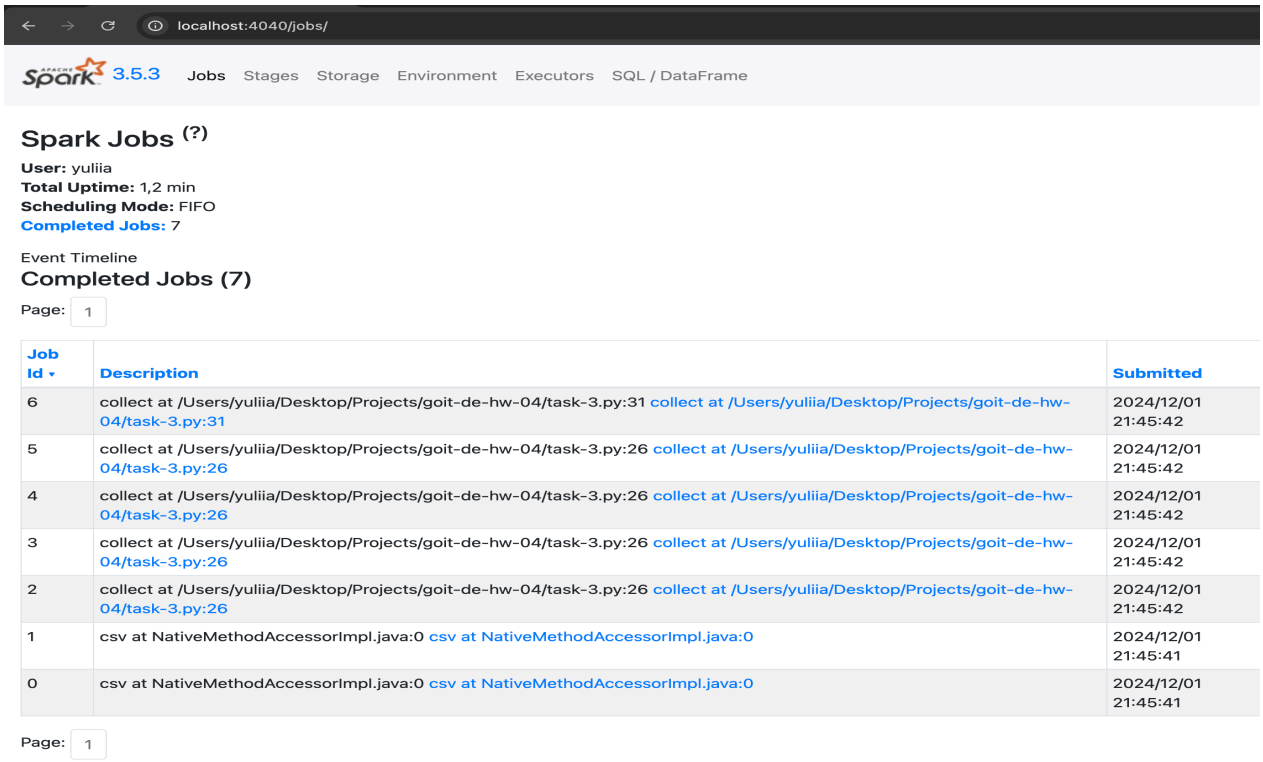

Чому при використанні cache() ми зменшили кількість Job?

1. Перше виконання дій на закешованому DataFrame (наприклад, перший collect()) включає всі обчислення до точки кешування та зберігає результат. Це 5 Jobs.
2. Подальші дії на закешованих даних виконуються без повторних обчислень і лише на закешованих результатах. Це зменшує додаткові Jobs до 2 (для фільтру where("count > 2") та фінального collect()).

Загалом: 7 Jobs.